

In-Datcenter Performance Analysis of a Tensor Processing Unit

Grupo #4

MP6160 Diseño de Alto Nivel | II Cuatrimestre
2026

Contexto y Motivación

Auge del Deep Learning (2013-2016): demanda de cómputo en datacenters de Google crece exponencialmente

Limitaciones de CPUs: rendimiento insuficiente para inferencia a escala

Limitaciones de GPUs (K80): optimizadas para throughput, no latencia P99; solo 1.1x vs CPU en inferencia real

Motivación del TPU: ASIC personalizado para inferencia con meta de 10x perf/watt vs GPU

Restricción clave: despliegue en 15 meses, compatible con infraestructura existente (PCIe, TensorFlow)

Problema Principal

OBJETIVO

Acelerar inferencia de redes neuronales en datacenter con 10x mejora en rendimiento por vatio respecto a GPUs

REQUISITOS

- Bajo costo de implementación
- Bajo consumo energético
- Compatibilidad con TensorFlow
- Despliegue rápido (15 meses)
- Integración con infraestructura existente

Metodología de Diseño

Enfoque Top-Down (dominante):


1. Necesidades de negocio: ASIC, meta 10x perf/watt
2. ISA: ~12 instrucciones CISC (MatrixMultiply, Activate, Read/Write Host)
3. Microarquitectura: matriz 256x256, pipeline 4 etapas, CPI 10-20
4. Dimensionamiento con modelo roofline
5. Latencia determinística: sin cache, sin OoO, single-threaded

Reutilización Bottom-Up:

PCIe Gen3 x16 | DDR3 8GB | Proceso 28nm

Arq. sistólica (Kung & Leiserson, 1980)

TensorFlow como interfaz | INT8: 6x menos energía que FP16



65,536 MACs en TPU (256x256) → 92 TOPS pico @ 700 MHz


Arquitectura del Sistema

Matrix Multiply Unit (30% del die)
65,536 MACs INT8 (256x256), 92 TOPS pico, ejecucion sistolica
Acumuladores: 4 MiB (32-bit), 4096 unidades

Unified Buffer (29% del die)
24 MiB SRAM on-chip, almacena activaciones intermedias

Weight Memory + FIFO
8 GiB DDR3 off-chip, 30 GB/s BW | 4 tiles, decoupled access-execute

Activation Unit: ReLU, Sigmoid, tanh, pooling
Interfaz PCIe: Gen3 x16, TPU como coprocesador
Control: Solo 2% del die (vs ~30% en CPUs)



Distribución de Área

~37% Buffers de Datos

Unified Buffer (24 MiB) + Weight FIFO
Mayor porción del área, prioridad en ancho de banda

~30% Cómputo (MMU)

65,536 MACs en matriz sistólica 256x256
Optimizado para multiplicación de matrices

~10% Entrada/Salida

Interfaz PCIe Gen3 x16 hacia host
Comunicación con CPU

~2% Control

Instrucciones CISC, pipeline simplificado
vs ~30% en CPUs de propósito general

Area total del die: ~331 mm² en 28nm

Software Stack

TensorFlow

Framework de usuario — define grafos computacionales
API de alto nivel para redes neuronales

Compilador TPU (XLA)

Compila subgrafos a instrucciones TPU
Optimiza fusión de operaciones y layout de memoria

User Space Driver

Interfaz de comunicación con el hardware
Maneja buffers y sincronización

Kernel Driver

Gestión directa del hardware, interrupciones, DMA

Hardware TPU

Coprocador conectado vía PCIe al host



Comparativa Plataformas

Característica	Haswell CPU	NVIDIA K80	TPU v1
Núcleos/ALUs	18 cores	2496 ALUs	65,536 MACs
Proceso	22nm	28nm	28nm
Frecuencia	2.3 GHz	560 MHz	700 MHz
TDP	145W	150W	40W
Memoria	DDR4	12 GiB GDDR5	8 GiB DDR3
Ancho de banda	51.2 GB/s	480 GB/s	30 GB/s
Rendimiento pico	—	2.8 TFLOPS	92 TOPS

TPU: 3.6x mejor perf/watt que GPU

Rendimiento Resultados

TPU vs CPU (promedio ponderado)

29.2× más rápido en inferencia

Domina en cargas con alta intensidad aritmética

GPU vs CPU

Solo 2.7× más rápida — limitada por latencia batch

TPU vs K80 (GPU)

~15× más rápido en inferencia

Resultados por modelo:

MLP0: 41× vs CPU | MLP1: 2.5×

LSTM0: 3.5× vs CPU | LSTM1: 71×

CNN0: 40× vs CPU | CNN1: 71×

Conclusión: TPU excels en MLPs y CNNs densos

Roofline: 92 TOPS pico (INT8), 30 GB/s BW; 4/6 DNNs memory-bound

Latencia P99: 7ms, cumple SLA en 5/6 DNNs; batch=1 para min. latencia

TDP: 40W vs GPU 180W vs CPU 455W

Perf/Watt: 83x vs CPU, 29x vs GPU; cooling pasivo viable

Restricciones y Tradeoffs

Escalabilidad:

- Coprocesador PCIe (sin cambios en host)
- Supercomputer Pod: 64 TPUs interconectados
- Escalamiento horizontal simple por diseño modular

Complejidad y Flexibilidad:

- ISA CISC: instrucciones de alto nivel reducen overhead
- Solo inferencia (no entrenamiento) en v1
- INT8/16 (sin FP32 nativo), programabilidad restringida vs GPU
- Dependencia del compilador XLA para optimización

Roofline Adaptado: TOPS en lugar de FLOPS, intensidad ops/byte ponderada

Modelo analítico: error < 10% vs hardware real, 106 contadores HW

Benchmarking: 6 apps reales (95% workload), latencia P99 completa

Verificación: simulación chip completo pre-silicon, misma gen tecnológica

106 contadores
profiling HW

6 apps reales
95% workload

Aplicaciones y Relevancia

Aplicaciones en producción: Voice Search, Inception V2, AlphaGo, GNMT, RankBrain

Evolución: v1 (92 TOPS) → v2 (180 TF) → v3 (420 TF) → v4 → v5 (escala masiva)

Legado: NVIDIA Tensor Cores, Apple Neural Engine, AWS Inferentia, Meta MTIA

Impacto científico: ISCA 2017, 6000+ citas, era de DSAs (Domain-Specific Architectures)

Reconocimiento: Hennessy & Patterson Turing Award 2019

6000+ citas
ISCA 2017

5+ empresas
con DSAs propios

Conclusiones

Rendimiento: 92 TOPS en 28nm con solo 40W TDP

Latencia P99: predecible para servicios en producción

TCO: 15-30x mejor que GPU/CPU para inferencia NN

Time-to-market: diseño completado en solo 15 meses

Validación: enfoque DSA validado con cargas reales de producción

Limitaciones: solo inferencia, INT8/16, sin FP32 nativo, dependencia de host CPU

Flexibilidad: restringida vs CUDA, pobre proporcionalidad energética (88% idle power)

Referencias

Jouppi et al.: "In-Datacenter Performance Analysis of a TPU," ISCA 2017

Patterson et al.: "A Domain-Specific Architecture for DNNs," CACM 2018

Hennessy & Patterson: "A New Golden Age for Computer Architecture," ISCA 2019

Google Cloud: TPU Documentation, cloud.google.com/tpu

Declaración de uso de IA

Para la elaboración de esta presentación se utilizaron herramientas de Inteligencia Artificial. Se utilizó Claude para la síntesis, revisión y generación de diagramas y Canva IA para formatear el entregable.

Prompt para Claude: "En base a este documento (compilación de notas tomadas por los estudiantes) elabora el contenido para las diapositivas de una presentación, incluyendo diagramas y layout."

Prompt para Canva IA: "Genera un tema moderno y minimalista, utilizando colores oscuros y tonos verdes azulados, para una presentación relacionada a la tecnología."